

Análise Preditiva e Descritiva da Popularidade Musical no Spotify: Uma Abordagem KDD utilizando Machine Learning

Análise Preditiva e Descritiva da Popularidade Musical no Spotify: Uma Abordagem KDD utilizando Machine Learning

Nome do Aluno: Raphael Sena Olicerio

RA: 12524126329

Disciplina: Análise de Dados e Big Data

Professor: Edquel Bueno Prado Farias

Instituição: Anhembi Morumbi

Trabalho de Conclusão de Semestre apresentado como requisito parcial para obtenção do título de Análise de Dados e Big Data

Orientador: Edquel Bueno Prado Farias

São Paulo, 20 de maio de 2026

RESUMO

Este artigo descreve a aplicação completa do processo de Descoberta de Conhecimento em Bases de Dados (KDD) em um conjunto de dados do Spotify, com o objetivo de analisar e prever a popularidade das músicas. O estudo utilizou uma stack técnica focada em código (Python, Scikit-Learn e Streamlit). Foram aplicadas três abordagens de Inteligência Artificial: Regressão Linear, Árvore de Decisão e agrupamento via K-Means. A principal descoberta revelou que atributos puramente sonoros (como energy ou danceability) não são suficientes para prever a popularidade exata matematicamente (R^2 de 6,5%), mas o modelo de Classificação provou que o "Gênero Musical" é o fator preditivo mais importante (importância de 0.68) para definir o nível de sucesso de uma faixa.

Palavras-chave: KDD, Machine Learning, Spotify, Scikit-Learn, Streamlit.

ABSTRACT

This article describes the complete application of the Knowledge Discovery in Databases (KDD) process on a Spotify dataset, aiming to analyze and predict song popularity. The study utilized a code-focused technical stack (Python, Scikit-Learn, and Streamlit). Three Artificial Intelligence approaches were applied: Linear Regression, Decision Tree, and K-Means clustering. The main discovery revealed that purely sonic attributes (such as energy or danceability) are not sufficient to mathematically predict exact popularity (R^2 of 6.5%), but the Classification model proved that "Musical Genre" is the most important predictive factor (importance of 0.68) for defining a track's success level.

Keywords: KDD, Machine Learning, Spotify, Scikit-Learn, Streamlit.

1. INTRODUÇÃO

A indústria musical moderna é fortemente orientada por dados, com plataformas de streaming como o Spotify utilizando algoritmos complexos de recomendação. Neste cenário, surge o problema de pesquisa que norteia este trabalho: "O que faz uma música ser popular? É possível prever o nível de sucesso de uma faixa utilizando seus atributos sonoros e o seu gênero musical?".

A justificativa para esta análise reside no valor estratégico para o mercado fonográfico. Entender os padrões que levam uma música a se tornar um "Hit" permite que gravadoras e produtores otimizem seus investimentos. O objetivo deste trabalho é aplicar o processo KDD para extrair padrões dessa base de dados, implementando, avaliando e comparando o desempenho de três algoritmos distintos de Inteligência Artificial.

2. REFERENCIAL TEÓRICO

2.1. O Processo de Descoberta de Conhecimento (KDD)

O processo KDD (Knowledge Discovery in Databases), conforme descrito por Fayyad et al. (1996), é uma sequência sistemática de etapas que visa extrair padrões válidos, novos, potencialmente úteis e compreensíveis a partir de grandes volumes de dados. As fases principais incluem seleção, pré-processamento, transformação, mineração de dados e avaliação/interpretação. Cada fase é crucial para garantir a qualidade, a ausência de vieses e a relevância do conhecimento descoberto para a tomada de decisão estratégica.

2.2. Tecnologias e Ferramentas Aplicadas

Para a execução de projetos de KDD, a literatura e o mercado sugerem diversas ferramentas de código aberto que oferecem flexibilidade e recursos de nível profissional. Embora existam suítes com interfaces gráficas intuitivas (como Weka, KNIME e Orange) que facilitam a aplicação de algoritmos e limpeza visual de dados, este projeto adotou uma arquitetura focada inteiramente em código estruturado. As tecnologias fundamentais selecionadas foram:

- **Python e Ecossistema de Dados:** Escolha profissional para automação e reprodutibilidade. Utilizou-se a biblioteca Pandas para a etapa de manipulação, limpeza profunda de dados e tratamento de inconsistências (atuando no lugar de ferramentas visuais como o OpenRefine).
- **Scikit-Learn:** Biblioteca nativa do Python designada para a implementação de algoritmos de aprendizado de máquina. Ela foi a base da fase de mineração de dados deste estudo, suportando eficientemente a execução da Regressão Linear, Árvore de Decisão e agrupamento via K-Means.
- **Streamlit (Visualização Interativa):** A última fase do KDD exige a comunicação clara dos resultados gerados. Embora ferramentas de Business Intelligence clássicas como Power BI ou Tableau Public sejam amplamente sugeridas para a criação de painéis dinâmicos, optou-se pelo uso da biblioteca Streamlit. Essa escolha permitiu desenvolver um dashboard interativo via código Python, garantindo integração direta e em tempo real com os modelos de Inteligência Artificial treinados pelo grupo.

3. METODOLOGIA

A metodologia adotada seguiu as etapas do processo KDD (Seleção, Pré-processamento, Transformação, Mineração de Dados e Avaliação) conforme proposto por Fayyad et al. (1996).

Perfil e Stack de Ferramentas:

Adotou-se o perfil "Focado em Código", conforme detalhado na Tabela 1:

Perfil do Grupo	Ferramenta de Limpeza	Ferramenta de Mineração	Visualização
Focado em Código	Python (Pandas)	Python (Google Colab)	Streamlit / Plotly

Seleção e Pré-processamento:

A base de dados escolhida contém dados de faixas do Spotify. Foi realizada uma rigorosa Análise Exploratória de Dados (EDA) prévia. Na etapa de limpeza, efetuou-se o tratamento de valores nulos e a remoção de duplicatas. Utilizou-se o método de Boxplot para detecção de outliers em variáveis como loudness e tempo.

Transformação:

Os dados numéricos foram normalizados e as variáveis categóricas foram transformadas através de Label Encoding (ex: criação da variável `track_genre_encoded`). O dataset foi dividido na proporção 80/20 para treino e teste.

Mineração de Dados (Inteligência Artificial):

Foram aplicados três algoritmos de diferentes categorias de IA:

- **K-Means (Agrupamento/Clustering):** Para identificar perfis sonoros naturais.
- **Árvore de Decisão (Classificação):** Para prever categorias de sucesso (Obscura, Em Ascensão, Mainstream, Hit).
- **Regressão Linear (Regressão):** Para tentar prever o valor numérico exato da popularidade.

Os modelos supervisionados foram validados através de Validação Cruzada (5-fold) para garantir a estabilidade e capacidade de generalização.

4. RESULTADOS E DISCUSSÃO

Nesta seção, são apresentados os resultados obtidos após a execução do pré-processamento e da mineração de dados, baseando-se no framework KDD. O objetivo central foi identificar os fatores que determinam a popularidade de uma faixa no Spotify, comparando a eficácia de três abordagens distintas de Inteligência Artificial: Agrupamento (K-Means), Regressão (Regressão Linear) e Classificação (Árvore de Decisão).

4.1. Análise Exploratória e Tratamento de Dados (EDA)

Antes da aplicação dos modelos, a análise exploratória revelou a alta dimensionalidade e a presença de ruídos nos dados brutos do Spotify.




Figura 1: À esquerda, boxplots demonstrando a detecção de outliers em variáveis sonoras. À direita, o mapa de calor da correlação de Pearson entre as features.

Discussão: A Figura 1 ilustra a etapa de limpeza e a correlação inicial dos dados. Observou-se uma quantidade substancial de outliers em variáveis fundamentais como tempo, loudness e duration_min. O tratamento desses valores foi essencial para não enviesar os algoritmos. Mais criticamente, o mapa de correlação evidenciou que atributos sonoros isolados (como energy ou

danceability) possuem uma correlação linear muito fraca com a variável alvo popularity. Para o negócio, isso foi o primeiro indício de que a "fórmula do sucesso" não é uma simples soma matemática de elementos acústicos, exigindo técnicas não-lineares e de agrupamento para ser desvendada.

4.2. Identificação de Perfis Sonoros (K-Means)

A primeira abordagem de Inteligência Artificial visou o aprendizado não-supervisionado para descobrir se existiam segmentações naturais na base de músicas.




Figura 2: Gráficos do Método do Cotovelo e Silhouette Score para definição de K, seguidos pelo mapa de calor dos perfis médios dos clusters encontrados.

Discussão: Para garantir o rigor matemático na escolha dos agrupamentos, utilizou-se o Método do Cotovelo associado ao Silhouette Score. A Figura 2 demonstra que o ponto de inflexão ideal (cotovelo) ocorre em K=4, alcançando um Silhouette Score de 0.5432. Este resultado indica um grau

de separação moderado a bom. Ao analisar o perfil médio dos clusters, foi possível rotular 4 nichos sonoros na plataforma (variando de acústicos/calmos a eletrônicos/energéticos). Implicação para o Negócio: Esta clusterização permite que gravadoras e produtores segmentem seu catálogo. Embora não preveja diretamente o sucesso, mapear a "identidade sonora" de uma faixa ajuda as equipes de marketing a direcionar a música para a playlist de recomendação correta no Spotify.

4.3. Regressão Linear: A Limitação dos Atributos Acústicos

Na tentativa de prever a nota exata de popularidade (0 a 100), aplicou-se a Regressão Linear.




Figura 3: Análise de desempenho da Regressão Linear, demonstrando o gráfico de Real vs. Previsto, a distribuição de resíduos e os coeficientes das features.

Discussão: A Figura 3 revela os limites dos dados puramente sonoros. O modelo obteve um Coeficiente de Determinação (R^2) de apenas 0.0654 no conjunto de teste, com um Erro Médio Absoluto (MAE) de 0.15. Visualmente, o gráfico de "Real vs. Previsto" evidencia a alta dispersão dos dados, mostrando que o modelo é incapaz de traçar uma linha de tendência confiável apenas com atributos físicos da faixa. Implicação para o Negócio: O R^2 de 6,5% é um insight estratégico crucial. Ele prova matematicamente que tentar projetar um "Hit" focando estritamente em deixá-lo mais "dançante" ou mais "alto" no estúdio é uma estratégia ineficaz. O sucesso mercadológico é fortemente impulsionado por variáveis exógenas à música em si, como o investimento em marketing da gravadora, o engajamento prévio da base de fãs e os algoritmos de recomendação algorítmica da plataforma.

4.4. Árvore de Decisão: O Peso Estratégico do Gênero Musical

Diante do baixo desempenho da regressão, o problema foi reestruturado para uma abordagem de Classificação, categorizando a popularidade em faixas de sucesso (Obscura, Em Ascensão, Mainstream, Hit). Utilizou-se o algoritmo de Árvore de Decisão com profundidade limitada a 7 para

evitar o superajuste (overfitting).




Figura 4: Matriz de Confusão e gráfico das 10 features mais importantes (Índice de Gini) extraídos da Árvore de Decisão.

Discussão: A Árvore de Decisão superou largamente a modelagem linear. O modelo alcançou uma acurácia de 57.1% e um F1-Score de 0.523, com uma estabilidade comprovada pela validação cruzada 5-fold (média de 56.3%). A Matriz de Confusão mostra que o modelo foi muito competente em separar músicas "Obscuras" das que estão "Em Ascensão". O resultado mais impactante desta pesquisa encontra-se no gráfico de Importância de Features (Figura 4). A variável categórica do gênero musical (`track_genre_encoded`) dominou o processo decisório do algoritmo, alcançando um grau de importância (Gini) de 0.6831, muito superior a características como acústica ou volume.

Implicação para o Negócio: Este resultado sugere que a Árvore de Decisão foi altamente eficaz em capturar relações hierárquicas e não-lineares. Para a indústria fonográfica, o insight é claro: o ecossistema (Gênero) importa mais do que a técnica (Atributos Sonoros). Lançar a música no nicho de gênero adequado dita quase 70% da sua capacidade de escalar nas paradas de popularidade, devendo ser o foco principal das equipes de A&R (Artists and Repertoire).

4.5. Comparação e Avaliação dos Modelos




Figura 5: Comparativo final das métricas de desempenho técnico entre as três arquiteturas de Inteligência Artificial testadas.

A Figura 5 sintetiza a resposta ao problema de pesquisa proposto. Fica evidente que a natureza dos dados musicais rejeita análises de regressão linear restritas à acústica. No entanto, ao utilizar técnicas como o K-Means para entendimento exploratório de nichos e a Árvore de Decisão para classificar regras de negócios pautadas no Gênero Musical, é possível criar um sistema preditivo robusto. Cumprindo o objetivo do framework KDD, os dados brutos foram transformados em conhecimento aplicável: o produtor musical deve focar no som da música, mas é o executivo de negócios, ao posicionar corretamente o Gênero, quem define a probabilidade de a faixa se tornar um sucesso.

5. CONCLUSÃO

Este trabalho aplicou o processo KDD e técnicas de IA para desmistificar a popularidade no Spotify. A análise comprovou que, embora seja difícil cravar uma pontuação exata usando apenas características sonoras (Regressão), é possível prever faixas de sucesso utilizando o Gênero como guia estratégico (Árvore de Decisão). O painel em Streamlit consolidou esses insights.

Como limitação, destaca-se a ausência de variáveis mercadológicas. Para trabalhos futuros, sugere-se a inclusão de dados externos e a aplicação de Redes Neurais Artificiais ou técnicas de Ensemble.

6. REFERÊNCIAS

FAYYAD, U. M.; PIATETSKY-SHAPIO, G.; SMYTH, P. From Data Mining to Knowledge Discovery in Databases. **AI Magazine**, v. 17, n. 3, p. 37-54, 1996.

PANDYA, M. **Spotify Tracks Dataset**. Kaggle. Disponível em: <https://www.kaggle.com/datasets/maharshipandya/-spotify-tracks-dataset>. Acesso em: 18 maio 2026.

PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. **Journal of Machine Learning Research**, v. 12, p. 2825-2830, 2011.